

2025년 8월 현재 최신 모델 분석

2025년 8월 기준으로 OpenAI, Google, Anthropic은 각각 다음과 같은 최신 AI 모델을 발표하였습니다.

1. 최신 모델

🧠 OpenAI GPT-5 (신규 기본 모델)

- **포지션:** ChatGPT의 기본 모델로 채택, API도 동시 공개. “통합 시스템”으로 빠른 응답 모델과 **깊은 추론용 GPT-5 Thinking**을 라우터가 자동 선택. 상위 버전 **GPT-5 Pro** 제공.
- **모드:** ChatGPT에서 **Auto / Fast / Thinking** 3가지 모드 선택 가능(Plus/Pro 한도 상이).
- **맥락 길이:** API의 GPT-5 계열은 **최대 총 400k 토큰(입력 272k + 추론·출력 128k)**. ChatGPT의 GPT-5 Thinking은 안내 기준 196k.
- **성능 포인트(공식):** AIME 2025 **94.6%**, SWE-bench Verified **74.9%**, MMMU **84.2%**, HealthBench Hard **46.2%** 등에서 SOTA 수준. 환각·사실 오류 감소와 스타일·복종성(아부) 개선 강조.
- **API 구성:** **gpt-5**, **gpt-5-mini**, **gpt-5-nano** 등 사이즈 옵션과 개발자 제어 파라미터(예: reasoning_effort, verbosity).

🔍 Google Gemini 2.5 (Pro / Flash / Flash-Lite / Live)

- **포지션:** “생각(Thinking) 내장” 차세대 모델 군. **2.5 Pro**(정밀 추론·코딩), **2.5 Flash**(가격·성능), **2.5 Flash-Lite**(저지연·저비용), **2.5 Flash Live**(실시간 음성·영상 인터랙션).
- **입출력/맥락:** Pro/Flash/Flash-Lite 모두 **입력 1,048,576 토큰, 출력 65,536 토큰**(Live는 별도 제한). **지식 컷오프 2025-01** 표기.
- **멀티모달:** 텍스트·이미지·오디오·비디오 입력 지원(모델별 상이). **2.5 계열은 이미지 생성 미지원**—이미지 생성은 **2.0 Flash Preview Image Generation**을 별도 사용.

🧑‍🦧 Anthropic Claude 4 계열 (Opus 4.1 / Sonnet 4)

- **포지션:** 2025-05 **Claude 4(Opus 4, Sonnet 4)** 공개 이후, 2025-08-05 ‘Opus 4.1’로 에이전틱 작업·실전 코딩·추론 성능 보강. Sonnet 4는 **맥락 1M 토큰(베타)** 지원 발표(2025-08-12).
- **모달리티/맥락:** 공식 개요 문서상 **텍스트·이미지 입력 / 텍스트 출력, 기본 200k 컨텍스트(일부 1M 베타)**.
- **배포:** Anthropic API, **AWS Bedrock**, **Google Vertex AI** 등에서 이용 가능.

2. 최신 모델 비교

2025년 8월 현재, OpenAI, Google, Anthropic의 최신 AI 모델들은 코딩, 수학, 시각적 추론 등 다양한 분야에서 뛰어난 성능을 보이고 있습니다. 아래는 각 모델의 주요 성능 비교입니다.

📊 종합 비교

모델	MMLU	SWE-Bench Verified (코딩)	AIME (수학)	GPQA (QA)	MRCR (대화 이해)	Context 윈도우	토큰당 비
GPT-5 (OpenAI)	87.0% (MMLU-Pro)	74.9%	94.6% (AIME 2025, no tools)	85.7% (Diamond) / 88.4% (Pro)	95.2% @128k / 86.8% @256k	400k 입력 / 최대 출력 128k	입력 \$1.2 / \$10 (1M 토큰)
GPT-4.1 (OpenAI)	90.2%	54.6%	48.1% (AIME 2024)	66.3% (Diamond)	57.2% @128k / 46.3% @1M	최대 1,000,000 토큰	입력 \$2 / \$8 (1M 토큰 시드 입력)
Gemini 2.5 Pro (Google)	86.2%	63.8%	AIME 2024: 92% / 2025: 86.7%	84.0% (GPQA Diamond)	91.5% (MRCR)	입력 1,048,576 / 출력 65,536	입력 \$1.2 / \$10
Claude Opus 4 (Anthropic)	–	72.5%	–	–	–	200,000 토큰 (Sonnet 대비)	입력 \$15 / \$75

- Massive Multitask Language Understanding, **MMLU**: 일반 지식, 논리, 추론, 윤리

- Massive Multi-discipline Multimodal Understanding, **MMMU**: 시각적 추론
- Software Engineering Benchmark, **SWE-Bench**: 실전 코딩 능력
- American Invitational Mathematics Examination, **AIME**: 수학 추론
- Graduate-level Google-Proof Q&A, **GPQA**: 검색으로는 쉽게 찾을 수 없는 대학원 수준 전문 질의응답
- Multi Round Conversational Reasoning, **MRCR**: 대화 기반 추론 능력

특정 분야나 사용 목적에 따라 적합한 모델을 선택하시는 것이 중요합니다.

코딩 (SWE-Bench Verified 기준)

- **GPT-5**가 공개 수치 기준 74.9%로 가장 높습니다(에이전틱 코딩 강화).
- **Claude Opus 4**는 72.5%로 근소하게 뒤따릅니다(지속 작업·긴 시나리오 강점).
- **Gemini 2.5 Pro**는 59.6%(단일)/67.2%(다중 시도)입니다. 구글은 다중 시도·재채점 스캐폴딩을 별도로 안내합니다.

수학 (AIME 기준)

- **GPT-5**가 94.6% (도구 미사용)로 최고치를 보고합니다.
- **Gemini 2.5 Pro**는 88.0% (단일 시도)로 강세입니다.
- **Claude Opus 4**는 **33.9% (extended thinking 미사용)** 기준 수치를 공개했습니다(확장 추론 적용 시는 별도 표기).

시각적 추론 (MMMU)

- **GPT-5**가 84.2%로 가장 높게 보고되었습니다.
- **Gemini 2.5 Pro**는 82.0% (단일 시도)로 근접합니다.
- **Claude Opus 4**는 73.7% (extended thinking 미사용)입니다.

3. 요약

모델	코딩 (SWE-bench Verified)	수학 (AIME 2025)	시각적 추론 (MMMU)
GPT-5 (OpenAI)	74.9%	94.6% (<i>no tools</i>)	84.2%
Gemini 2.5 Pro (Google)	59.6% 단일 시도 / 67.2% 다중 시도	88.0% 단일 시도	82.0% 단일 시도
Claude Opus 4 (Anthropic)	72.5%	33.9% (<i>extended thinking 미사용</i>)	73.7% (<i>extended thinking 미사용</i>)